中国科学院大学
University of Chinese Academy of Sciences

研究生学位论文开题报告

报告题目 病原参比数据库的构建与评估

学生姓名 刘昊宸 学号 202428016715019

指导教师 方向东 职称 研究员

学位类别 理学硕士

学科专业 生物信息学

研究方向 生物数据挖掘与整合

研究所（院系） 国家生物信息中心

填表日期 2025.12.15

中国科学院大学制

填 表 说 明

1. 本表内容须真实、完整、准确。
2. “学位类别”名称：学术型学位填写哲学博士、教育学博士、理学博士、工学博士、农学博士、医学博士、管理学博士，哲学硕士、经济学硕士、法学硕士、教育学硕士、文学硕士、理学硕士、工学硕士、农学硕士、医学硕士、管理学硕士等；专业学位填写工程博士、工程硕士、工商管理硕士（MBA）、应用统计硕士、翻译硕士、应用心理硕士、农业推广硕士、工程管理硕士、药学硕士等。
3. “学科专业”名称：学术型学位填写“二级学科”全称；专业学位填写“培养领域”全称。

报告提纲

1、选题的背景及意义
2、国内外本学科领域的发展现状与趋势
3、课题主要研究内容、预期目标
4、拟采用的研究方法、技术路线、实验方案及其可行性分析
5、已有研究基础与所需的研究条件
6、研究工作计划与进度安排
7、参考文献

1. 选题的背景及意义

当前，全球生物安全形势严峻，新发突发传染病频发。纵观历史，从 1918 年的西班牙大流感、2003 年的 SARS、到 2009 年的甲型 H1N1 流感和 2019 年的新冠肺炎(COVID-19)再到 2022 年的猴痘疫情，高致病病原微生物严重威胁人类生命健康与安全。世界卫生组织(World Health Organization, WHO)更是提出了“X 传染病”(Disease X)这一概念，以警示未来可能出现的由未知病原体引发的全球大流行病。在这一背景下，如何快速、准确地识别并应对新突发 X 传染病及生物安全，已被提升到国家安全的战略高度。

由于传统微生物学诊断技术受时效性、准确性及有限病原体检测范围的限制，难以满足临床复杂多变的病原体检测需求[1]。随着高通量测序技术的发展与普及，宏基因组测序(metagenomic Next-Generation Sequencing, mNGS)因其无偏倚、广覆盖的特性[2]，在传染病防控中发挥着十分重要的作用[3]。

该技术无需分离培养，能够直接对临床样本中的所有遗传物质进行测序，它尤其擅长鉴别罕见、新发、难以检测和混合感染的病原体。特别是在面对未知的 X 传染病时，mNGS 在病原体的识别、变异监测中发挥着不可替代的关键作用，在重大新发突发传染病疫情中，已成为鉴定识别病原体及其主要特征的最主要研究手段。

然而，mNGS 技术作为一种无预设的检测手段，其分析效能高度依赖于参考数据库的质量与完整性。目前，临床与科研机构普遍采用的 NCBI GenBank[4]或 RefSeq[5]等公共数据库，其本质是生物数据的“全量归档仓库”而非面向临床诊断的“专用参考数据集”。尽管其数据体量呈指数级增长，但在临床应用场景下却暴露出严重的适用性矛盾：

首先是数据信噪比低与冗余度高的双重挑战。由于公共数据库长期采取“用户自主上传“模式，缺乏严格的源头质控，导致大量条目不仅包含宿主序列污染、接头残留及分类学注释错误，更存在严重的序列冗余。在 mNGS 的高灵敏度检测中，这些“噪音数据”不仅显著增加了比对分析的计算负荷，严重制约检测时效性，更极易因非特异性匹配诱发假阳性结果，导致临床诊断的误判。

其次，关键元数据的结构化缺失严重阻碍了智能化病原谱的构建。据统计，

公共数据库中大量病原体条目缺乏规范化的“分离源(Isolation Source)”、“宿主(Host)”及”感染部位”等标签信息，或仅以非结构化的自由文本形式存在。这种语义互操作性的缺失，导致自动化分析流程无法根据特定临床场景（如”呼吸道感染”或”中枢神经系统感染”）实现目标样本的精准抓取与分类。现有的公共数据库因此难以支撑面向特定感染类型的精准溯源与智能化预警，无法满足临床对”场景化”检测数据库的迫切需求。

综上所述，现有公共数据库“高冗余、低质量、元数据缺失”等的特征，与临床 mNGS 对“高时效、高精准、智能化”的需求之间存在着根本性矛盾。要在海量复杂的生物数据海洋中实现高效的临床应用，必须改变传统直接复用公共数据的模式，建立全新的数据库构建范式。

基于此，本课题拟解决的核心科学问题是：如何在海量混杂的基因组数据中，界定并筛选出“最小的代表性基因组集合”，以实现对“最大病原生物学多样性”的高效覆盖。通过建立一种新的病原参比数据库范式，我们将为新突发“X 传染病”的快速识别与精准防控提供高质量的数据基石。

2. 国内外本学科领域的发展现状与趋势

在国际上，NCBI 的 RefSeq 及 GenBank 数据库虽是目前最权威的参考序列库，但在“大数据”向“精准数据”转化的过程中，现有的技术体系仍存在一定的滞后性。当前该领域的研究现状与技术瓶颈主要体现在以下两个具体维度：

首先，基因组序列的源头质控技术尚不完善，低质量数据清洗仍依赖后处理。虽然国际学术界已意识到数据污染问题，并开发了 GTDB-TK[6]（重构细菌分类学）和 GUNC[7]（检测嵌合体污染）等生物信息学工具来改善数据质量，但这些工具多侧重于分类学层面的修正，缺乏针对 mNGS 临床应用场景的深度清洗标准。公共数据库中依然存留大量未经严格鉴定的数据，如图 1 所示，许多条目仅被标记为“来源未验证(unverified source organism)”，这类数据在现有流程中很难被自动化工具精准剔除，是导致下游分析假阳性的直接技术诱因。

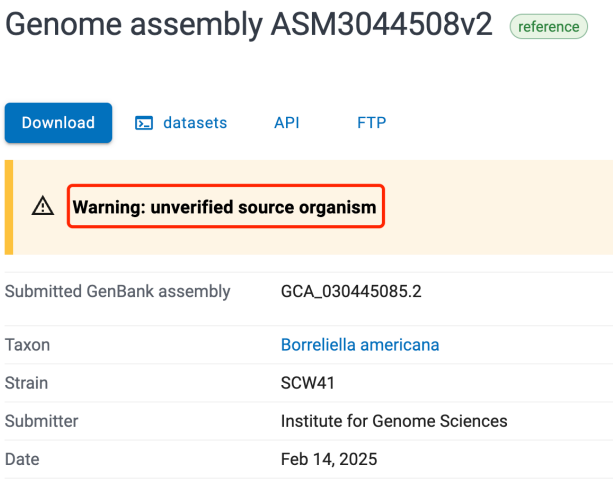

图 1 NCBI 数据库中“来源未验证”的条目示例

其次是元数据的结构化缺失与标准化不足，这是目前极易被忽视但至关重要的痛点。尽管 NCBI 存储了海量数据，但由于缺乏强制性的元数据录入标准，大量关键临床信息（如宿主类型、感染部位、采集时间）处于缺失或“非结构化”状态。本课题组前期对公共数据库的抽样调研显示，大量临床常见病原体的关键字段(如 Isolation Source)不仅存在严重的空白率(Missing Data),且描述方式极不统一。

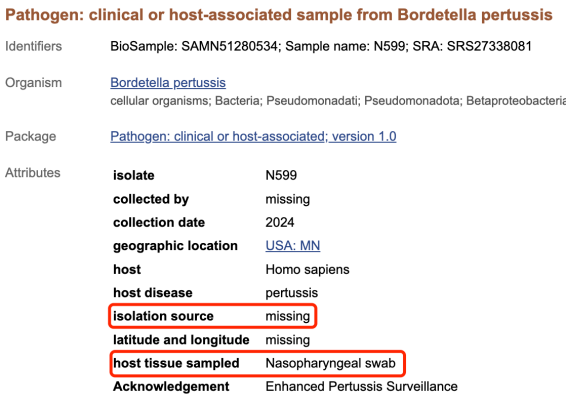

图 2 NCBI BioSample 数据库中百日咳鲍特菌(*Bordetella pertussis*)元数据缺失情况示例

正如图 2 所示，即便是在 BioSample 数据库中注册的样本，其核心字段也常标记为“缺失”或仅保留在非结构化的自由文本中。这种“语义互操作性”的匮乏，导致计算机无法自动抓取样本来源，直接阻断了基于特定临床场景（如“呼吸道来源”或“血流感染”）构建专用病原谱的可能性，这也正是现有公共数据库难以支撑智能化临床分析的根本原因之一。

在泛基因组学领域，随着计算能力的提升，研究重心正从单一参考基因组向泛基因组转变。现有工具如 Roary[8]、Panaroo[9]的开发使得大规模细菌群体的

基因组分析成为可能。然而，目前大多数研究集中在单一物种的进化分析，尚未有成熟的、覆盖多种临床病原体的泛基因组精简参考数据库发布。

我国在宏基因组测序技术的临床应用方面走在世界前列，但在基础数据库建设方面相对滞后。目前国内绝大多数 mNGS 服务商仍依赖自建的私有数据库，这些数据库大多直接清洗自 NCBI，缺乏统一的质控标准和更新机制，导致不同机构间的检测结果难以互认。以国内 mNGS 头部企业为例，其核心竞争力往往建立在基于海量临床样本积累的私有病原数据库(Proprietary Database)之上。这些数据库在 NCBI 等公共数据的基础上，通过内部算法剔除了特定的环境背景噪音(Background Noise)，并针对中国本土流行病原谱进行了人工校正。

与此同时，各实验室因测序平台与试剂环境的差异，各自维护着独立的“背景微生物基线库”(Baseline Database)。这种“一企一库”、“由于数据清洗标准不透明导致的黑盒化”现象，使得不同检测机构间的数据缺乏可比性，严重阻碍了多中心临床研究的开展与行业标准的统一。

近年来，我国已建设多个国家级数据中心[10]，但针对临床 mNGS 特定场景的、经过泛基因组深度清洗的专用数据库仍处于探索阶段。

总体而言，该研究领域正经历从“大数据”积累向“高质量智能数据”挖掘的深刻转变。盲目追求规模已非主流，未来核心趋势在于：利用算法筛选最具代表性的核心数据；以泛基因组分析取代单一参考基因组以应对高变异病原体；以及构建机器可读的标准化元数据，为人工智能辅助的智能化分析奠定基石。

3. 课题主要研究内容、预期目标

研究内容：

本课题围绕数据挖掘、差异化质控、算法筛选及效能评估四个层面展开：一是全量数据挖掘与元数据标准化。收集 NCBI 全量病原基因组，开发文本挖掘脚本清洗并补全“分离源”、“宿主”等关键字段，构建标准化索引体系。二是差异化多维质控体系。针对不同病原体实施特定策略：细菌端集成宿主去污、CheckM2[11]完整度评估、GTDB-TK 校正及 GUNC 去嵌合体；真菌端引入 BUSCO[12]评估；病毒端基于序列熵值与聚类剔除低质量序列。三是智能化筛选

算法。构建细菌泛基因组图谱并应用贪心集合覆盖算法筛选核心代表株；针对病毒和真菌开发基于 Mash[13]距离与全基因组比对的分层筛选流程。四是临床效能评估。利用模拟与真实临床数据，与 gcPathogen[14]、NCBI RefSeq 进行背对背评估，全面验证数据库的比对准确性、资源消耗及运行效率，以验证其在临床精准诊断中的实际价值。

预期目标：

(1) 构建病原参比数据库：完成覆盖超过 1000 种临床常见病原体的高质量病原微生物参比数据库构建；

(2) 验证算法效能：实现数据冗余度较全量数据库降低 10-20 倍，同时保持超过 95%的泛基因组非核心基因覆盖率（核心基因覆盖率>99%）；

(3) 推广建立标准流程：形成一套标准化的、可复制的病原微生物元数据清洗与标准化作业流程及数据库建设标准。

4. 拟采用的研究方法、技术路线、实验方案及其可行性分析

研究方法与技术路线：

4.1 病原微生物参比基因组研究方法与技术路线

本课题严格遵循“全量获取—多维质控—泛基因组筛选—效能评估”的闭环逻辑进行实施。首先依据 WHO 和 CDC 清单及《人间传染的病原微生物名录》等病原相关文献确定出 1790 种目标病原（其中细菌 627 种，病毒 549 种，真菌 423 种，寄生虫 191 种），优先获取 NCBI 完整基因组(Complete Genome)，不足时补充草图基因组(Draft Genome)。原始数据经宿主去污后，进入包含完整度、一致性、污染率及去嵌合体四重关卡的“多维质量门控体系”以确保数据纯净。随后，对通过质控的高质量数据进行注释，利用泛基因组算法筛选代表株。对于元数据的处理，我们直接溯源 NCBI 原始 JSONL 档案，利用脚本深入非结构化的 Attributes 字段，将深埋其中的“分离源”、“宿主”及“采集时间”等信息重新提取并标准化清洗，从而将被遗漏的关键元数据补全。最终结合代表基因组数据与标准化元数据构建数据库。最后，引入模拟及临床 mNGS 数据进行效能验证，重点考核数据库在“轻量化”与“高通量”环境下的实际

表现。最后通过定期增量更新与临床反馈验证，确保数据库始终处于最新、最准的活跃状态，实现了从构建到维护的完整闭环。

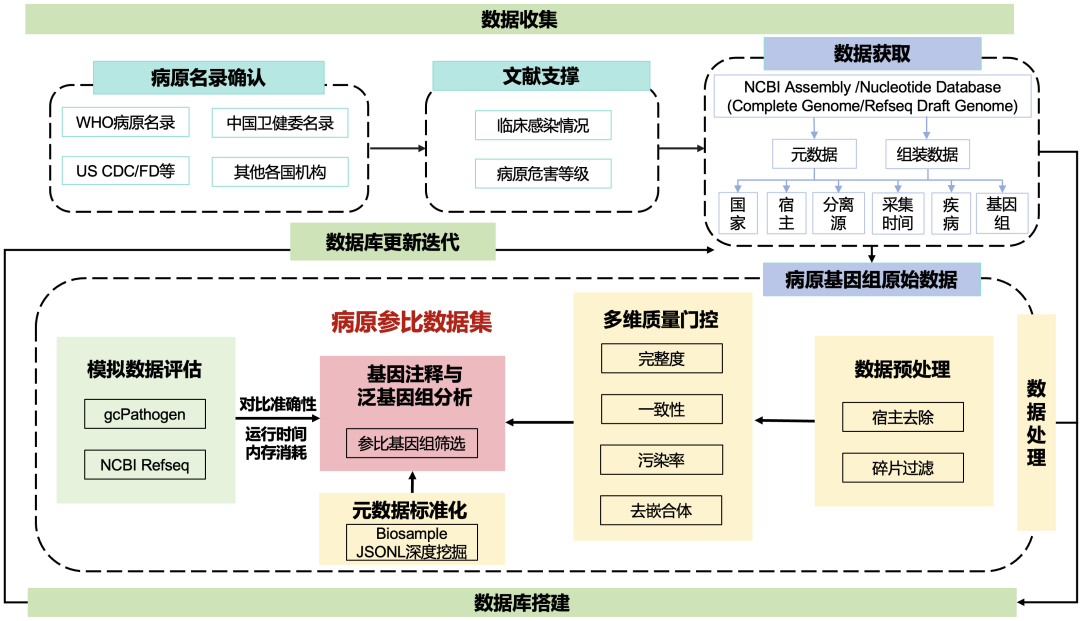

图 3 病原参比基因组筛选总技术路线

4.2 细菌参比基因组构建的精细化研究方法与技术路线

鉴于细菌全基因组数据量最为庞大且冗余度极高，如何从成千上万个菌株中筛选出最具生物学代表性的“最小集合”是本课题的核心技术难点。为此，我们针对细菌专门开发了一套基于泛基因组的“贪心集合覆盖算法”(Greedy Set Cover Algorithm)筛选流程。

该流程首先进行严格的数据预处理与多维质控。从 NCBI 下载的细菌完整基因组后通过 Minimap2 与 Samtools 工具去除宿主污染序列，随即实施三重严格质控：利用 CheckM2 工具评估基因组质量，设定完整度(Completeness)需大于等于 90%且污染度(Contamination)需小于等于 5%；利用 GTDB-Tk 工具进行高精度物种分类，要求平均核苷酸一致性(ANI)大于 95%以确保分类准确；最后利用 GUNC 工具检测并剔除嵌合体基因组(CSS score < 0.45)。只有通过上述所有质控标准的高质量纯净数据才能进入后续分析。

对于通过质控的数据，我们采用“先分簇，后贪心”的两步法策略来构建细菌参比基因组。首先，利用 Prokka[15]进行快速基因注释，再使用 Panaroo 构建泛基因组矩阵。为了有效处理庞大的计算任务并保留亚种水平的多样性，我们利用 Mash 算法计算基因组间的距离，按 99%相似度将菌株划分为不同 Cluster（亚

群）以保留亚种多样性。在每个 Cluster 内，基于泛基因组矩阵锁定的非核心基因(Dispensable genes)进行贪心迭代筛选：优先挑选携带独特非核心基因最多的菌株，并移除已覆盖基因，循环寻找贡献最大的下一菌株，直至代表株集合覆盖簇内 95%以上的非核心基因。该策略旨在大幅压缩数据的同时，确保稀有耐药基因或毒力因子等关键信息的完整保留。

我们所开发的这套“聚类+贪心”算法，能够在极大幅度压缩数据体积的同时，确保不遗漏任何一个 Cluster 中的关键遗传信息，实现了数据压缩与生物特征信息保真的完美平衡。

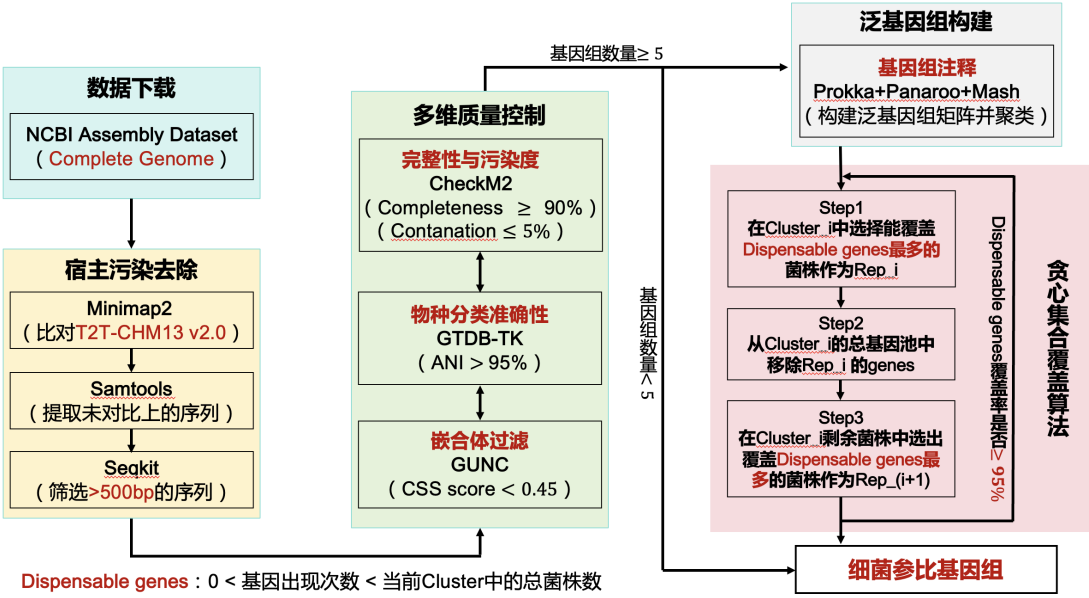

图 4 细菌参比基因组筛选技术路线

实验方案：

为了验证筛选流程的有效性，本课题前期以鼠疫耶尔森菌(*Yersinia pestis*)为例开展了全流程预实验。研究首先从 NCBI 数据库获取了 460 个鼠疫耶尔森菌的完整基因组数据，经 CheckM2 完整度评估与 GTDB-Tk 分类学校验后，进一步利用 GUNC 工具剔除 4 个嵌合体序列，最终保留 456 个高质量基因组用于泛基因组构建。

步骤	筛去数量	保留数量
初始数量	—	460
CheckM2	0	460
GTDB-TK	0	460
GUNC	4	456
泛基因组贪心算法	435	21

图 5 鼠疫耶尔森菌(*Yersinia pestis*)参比基因组的筛选统计图

在此基础上，应用本研究设计开发的贪心集合覆盖算法，从 456 个候选株中成功筛选出 21 个代表株。

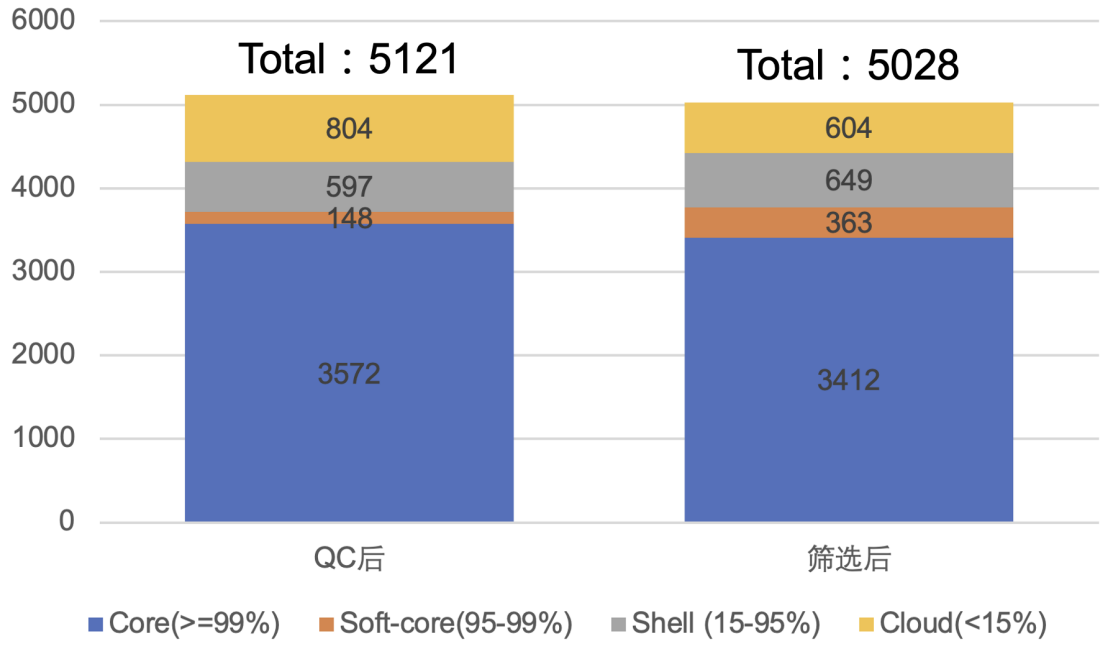

图 6 鼠疫耶尔森菌(*Yersinia pestis*)筛选前后泛基因组图谱对比柱状图

如图 6 所示，左侧为质控后泛基因组贪心算法筛选前 456 个菌株的泛基因组图谱，右侧为经过泛基因组贪心算法后最终筛选得到的 21 个代表菌株的泛基因组图谱，其结果表明，这仅占原始数据量 4.6%的 21 个代表株，实现了对 99%核心基因和 95%以上非核心基因的高度覆盖，本流程在将数据冗余度降低 20 倍的同时完整保留了病原体的遗传多样性。

该预实验的成功为后续将此方案推广至其他 500 种细菌乃至 1000 种病原体提供了坚实的实证依据。

可行性分析：

本研究在技术路径与资源保障上均具备充分可行性。技术层面，拟采用的“多维质控+泛基因组贪心算法”策略逻辑严谨，有效平衡了数据轻量化与信息完整性，且核心算法已通过概念验证。资源层面，课题组依托高性能计算集群与成熟的生物信息学团队，具备处理海量基因组数据的算力基础及流程开发能力；加之NCBI 公共数据库充足的数据储备，为课题的顺利实施提供了坚实的软硬件支撑。

5. 已有研究基础与所需的研究条件

目前，已成功搭建了整合 CheckM2、GTDB-Tk、GUNC 及 Panaroo 等核心工具的自动化生物信息学分析管线，并已顺利完成了 50 个细菌物种的参比基因组的筛选工作。以鼠疫耶尔森菌(*Yersinia pestis*)为例，该流程成功将 460 个原始基因组优化筛选为 21 个代表株，实现了在数据冗余度降低 95%以上的同时，泛基因组核心基因覆盖率>99%，非核心基因覆盖率>95%，并通过泛基因组饼图等多维图表充分证实了该筛选方案的高效性与科学性。

此外，已对 NCBI 现有数据的元数据缺失/不规范情况(如百日咳鲍特菌案例)进行了深入调研，明确了元数据清洗的具体方向。

本研究仅涉及公共数据库数据的二次挖掘与整理，不涉及人类遗传资源采集审批，符合生物安全与伦理规范。

所需研究条件：

1. 计算资源：课题组依托国家生物信息中心高性能计算集群，拥有充足的计算节点与 PB 级并行存储系统，完全满足海量基因组比对与泛基因组构建的算力需求。；

2. 数据资源：已完成 NCBI RefSeq 及 GenBank 细菌/病毒全量基因组数据的本地化镜像；

3. 技术与团队支撑：课题组在病原生物信息学领域积累了丰富的算法开发经验，已建立成熟的自动化分析流程(Pipeline)，并由经验丰富的指导教师团队提供全程技术指导。

6. 研究工作计划与进度安排

2025.12–2026.04 构建 600 种细菌参比数据集

2026.01–2026.07 开发病毒参比基因组筛选流程，构建 400 种病毒参比数据集

2026.03–2026.05 建立病原微生物元数据清洗与标准化流程

2026.05–2026.08 构建至少 1000 种病原微生物的标准化元数据集

2026.08–2026.11 开发并评估病原参比数据库

2026.10–2026.12 整理研究结果，准备中期答辩

2027.01–2027.03 撰写毕业论文，准备毕业答辩

7. 参考文献

[1] 刁振丽,李金明.宏基因组高通量测序技术的临床应用：现状、挑战与前景[J].协和医学杂志,2023,14(05):905-910.

[2] 范志琼.肺泡灌洗液宏基因组二代测序在肺部感染病原体检测及指导治疗中的价值探讨[D].昆明医科大学,2022.

[3] 刘长娜,刘军,韩冬.传染病监测与监测大数据应用的研究进展[J].职业与健康,2021,37(06):844-846+850.

[4] Benson D A, Cavanaugh M, Clark K, et al. GenBank[J]. Nucleic acids research, 2012, 41(D1): D36-D42.

[5] O'Leary N A, Wright M W, Brister J R, et al. Reference sequence (RefSeq) database at NCBI: current status, taxonomic expansion, and functional annotation[J]. Nucleic acids research, 2016, 44(D1): D733-D745.

[6] Chaumeil P A, Mussig A J, Hugenholtz P, et al. GTDB-Tk: a toolkit to classify genomes with the Genome Taxonomy Database[J]. 2020.

[7] Orakov A, Fullam A, Coelho L P, et al. GUNC: detection of chimerism and contamination in prokaryotic genomes[J]. Genome biology, 2021, 22(1): 178.

[8] Page A J, Cummins C A, Hunt M, et al. Roary: rapid large-scale prokaryote pan genome analysis[J]. Bioinformatics, 2015, 31(22): 3691-3693.

[9] Tonkin-Hill G, MacAlasdair N, Ruis C, et al. Producing polished prokaryotic pangenomes with the Panaroo pipeline[J]. Genome biology, 2020, 21(1): 180.

[10] 渠鸿竹,方向东.人类基因数据资源管理研究[J].中国科技资源导刊,2021,53(01):15-19.

[11] Chklovski A, Parks D H, Woodcroft B J, et al. CheckM2: a rapid, scalable and accurate tool for assessing microbial genome quality using machine learning[J]. Nature methods, 2023, 20(8): 1203-1212.

[12] Simão F A, Waterhouse R M, Ioannidis P, et al. BUSCO: assessing genome assembly and annotation completeness with single-copy orthologs[J]. Bioinformatics, 2015, 31(19): 3210-3212.

[13] Ondov B D, Treangen T J, Melsted P, et al. Mash: fast genome and metagenome distance estimation using MinHash[J]. Genome biology, 2016, 17(1): 132.
[14] Guo C, Chen Q, Fan G, et al. gcPathogen: a comprehensive genomic resource of human pathogens for public health[J]. Nucleic Acids Research, 2024, 52(D1): D714-D723.
[15] Seemann T. Prokka: rapid prokaryotic genome annotation[J]. Bioinformatics, 2014, 30(14): 2068-2069.