簇内贪心选择详解：

目的：在通过 **Mash** 确定的每一个遗传谱系（**Cluster**）内部，进一步去除冗余。目的是**选出最少数量的代表菌株，使其累加起来的基因集合能够覆盖该谱系内绝大多数（95%）的遗传多样性**。

原理与流程：

1. **锁定目标基因池**：
    - 我们不关注**核心基因 (Core Genes)**：因为簇内所有菌株都拥有核心基因，选任意一个代表株都能覆盖。
    - 我们也不关注**孤儿基因 (Unique Genes)**：仅在单株中出现的基因往往是测序噪音或非必要的移动元件，为了覆盖它们而保留所有菌株是不划算的。
    - **筛选重点**：锁定**"非核心基因 (Dispensable Genes)"**。即在当前簇内出现频率 >0 且 <100% 的基因。这部分基因代表了该谱系内的毒力、耐药及代谢多样性。
2. **最大边际增益迭代**：

    采用贪心算法（Greedy Algorithm）进行多轮迭代筛选，每一轮都致力于"在当前基础上获取最大的新信息量"。
    - **第 1 轮**：计算所有候选菌株携带的目标基因数量，选择**基因丰富度最高**的菌株作为首个代表。
    - **后续轮次**：
        - 计算剩余菌株中，每一个菌株所携带的、且**尚未被已选代表株覆盖的**新基因数量（即边际增益）。
        - 选择**增益最大**（能贡献最多新基因）的菌株加入代表库。
        - 更新已覆盖基因列表。
3. **饱和度终止**：
    - 重复上述迭代，直到已选代表株组合覆盖了目标基因池 **95%** 的内容。
    - 此时认为该组合已能充分代表该谱系的遗传特征，停止筛选。